

CutMix :

Regularization Strategy to Train Strong Classifiers With
Localizable Features

Tae-hwi Kim

ICCV, 2019

CutMix

- Main Contribution

1. **Data Level**에서 모델의 **일반화 성능을 향상**시키는 방법론 제안
2. 간단한 연산을 통해 **효율적인 overhead**로 이미지 증강 가능
3. Mixup과 비교했을 때, 보다 **명확하고 자연스러운 이미지**를 만듦
(식별이 쉬움 -> 모델의 Localization 성능을 향상)
4. 다른 기법에 비해 Adversarial sample에 대한 **Robustness 향상**

- Pros

- > 일반화 성능 향상, Detection에서 Localization(위치화) 성능 향상, 개선된 Robustness

- Cons

- > Sampling in Uniform Distribution -> 최적일까?
- > 너무 높은 랜덤성

CutMix

- Introduction

: CNN에서, 특정 이미지의 일부분에 대해 집중하는 현상이 생김, 이를 방지하기 위해 **Regional Dropout(input의 일부 영역으로 랜덤으로 삭제)하는 방식**이 사용

하지만 삭제된 영역은 대부분 0이 되거나 랜덤 노이즈 등으로 채워지는 경우가 많았다.
이는 데이터 양이 중요한 CNN에서 정보 손실을 일으킨다.
따라서 이 연구에서는 이 삭제된 영역을 **최대한 활용하고자 함**.

> 삭제된 영역을 다른 이미지의 일부(patch)로 대체하자 !



CutMix

- Method for Labels

그렇다면 Cut-mix된 이미지의 라벨은 뭐라고 해야 할까?

- > Mixup과 유사한 방식으로 새로운 라벨을 생성
Combination ratio λ 에 따라 새로운 라벨 \mathbf{y}^* 를 만든다.

$$\tilde{\mathbf{y}} = \lambda \mathbf{y}_A + (1 - \lambda) \mathbf{y}_B,$$

$$\lambda \in [0, 1]$$

Mixup에서, λ 값은 Beta Distribution인 $\text{Beta}(\alpha, \alpha)$ 에서 정해짐에 따라,
이때 CutMix에서도 베타 분포에서 α 값이 1인 $\text{Beta}(1,1)$, 균형을 이루는 분포인 Uniform Distribution에서 λ 값을 정한다.

- > 0부터 1까지 아무 값으로 정해질 확률이 일정하다.

CutMix

- Method for Images

Input Image 전체에 대한 **Binary Matrix(Width * Height) M**를 생성,
한 이미지에 대해 어떤 부분을 버릴 지(0), 어떤 부분을 유지할 지(1)를 결정하는 역할

$$\tilde{x} = \mathbf{M} \odot x_A + (\mathbf{1} - \mathbf{M}) \odot x_B$$

M에서 0으로 채울 영역(Crop할 영역)은 직사각형의 **Bounding Box B**를 통해 만들어진다.
B에 해당하지 않는 나머지는 모두 1로 둔다.

$$\begin{aligned} r_x &\sim \text{Unif}(0, W), & r_w &= W\sqrt{1-\lambda}, \\ r_y &\sim \text{Unif}(0, H), & r_h &= H\sqrt{1-\lambda} \end{aligned} \quad \frac{r_w r_h}{WH} = 1 - \lambda.$$

CutMix 될 두 개의 이미지는 하나의 미니 배치(mini-batch)에서 랜덤하게 선택된다.

CutMix

- Experiment Result

ImageNet Classification results, 더 큰 모델에 대해서도 좋은 성능 유지

Model	# Params	Top-1 Err (%)	Top-5 Err (%)
ResNet-152*	60.3 M	21.69	5.94
ResNet-101 + SE Layer* [15]	49.4 M	20.94	5.50
ResNet-101 + GE Layer* [14]	58.4 M	20.74	5.29
ResNet-50 + SE Layer* [15]	28.1 M	22.12	5.99
ResNet-50 + GE Layer* [14]	33.7 M	21.88	5.80
ResNet-50 (Baseline)	25.6 M	23.68	7.05
ResNet-50 + Cutout [3]	25.6 M	22.93	6.66
ResNet-50 + StochDepth [17]	25.6 M	22.46	6.27
ResNet-50 + Mixup [48]	25.6 M	22.58	6.40
ResNet-50 + Manifold Mixup [42]	25.6 M	22.50	6.21
ResNet-50 + DropBlock* [8]	25.6 M	21.87	5.98
ResNet-50 + Feature CutMix	25.6 M	21.80	6.06
ResNet-50 + CutMix	25.6 M	21.40	5.92

Table 3: ImageNet classification results based on ResNet-50 model. ‘*’ denotes results reported in the original papers.

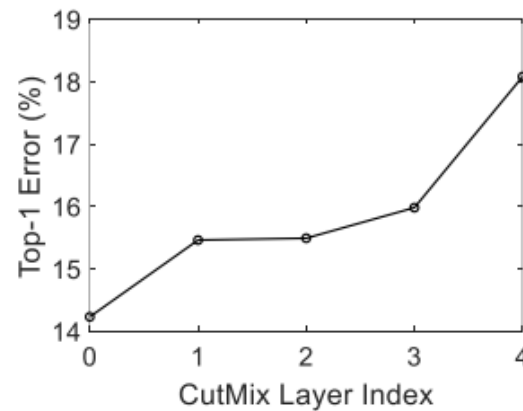

Model	# Params	Top-1 Err (%)	Top-5 Err (%)
ResNet-101 (Baseline) [12]	44.6 M	21.87	6.29
ResNet-101 + Cutout [3]	44.6 M	20.72	5.51
ResNet-101 + Mixup [48]	44.6 M	20.52	5.28
ResNet-101 + CutMix	44.6 M	20.17	5.24
ResNeXt-101 (Baseline) [45]	44.1 M	21.18	5.57
ResNeXt-101 + CutMix	44.1 M	19.47	5.03

Table 4: Impact of CutMix on ImageNet classification for ResNet-101 and ResNext-101.

CutMix

- Experiment Result – Ablation Study

최적의 α 값과 CutMix를 수행하는 Level에 대한 Ablation (CIFAR100, PyramidNet-200 사용)



Layer Index
0: Input Image
1: Conv-BatchNorm
2: Layer 1
3: Layer 2
4: Layer 3

Figure 3: Impact of α and CutMix layer depth on CIFAR-100 top-1 error.

CutMix

- Experiment Result – Ablation Study

CutMix Design에 따른 Ablation

- Center Gaussian CutMix

: r_x, r_y 를 이미지의 mean을 따르는

Gaussian Distribution으로 선택

- Fixed-sized CutMix

: 삭제할 영역을 16x16, Combination ratio λ 를 0.75로 고정

- Scheduled CutMix

: 훈련 동안 CutMix를 적용할 확률을 선형적으로 올림

- One-hot CutMix

: 더 많이 섞인 이미지의 라벨로 새로운 이미지의 라벨 결정

- Complete-label CutMix

: Combination ratio λ 를 0.5로 고정

PyramidNet-200 ($\tilde{\alpha}=240$) (# params: 26.8 M)	Top-1 Error (%)	Top-5 Error (%)
Baseline	16.45	3.69
Proposed (CutMix)	14.47	2.97
Center Gaussian CutMix	15.95	3.40
Fixed-size CutMix	14.97	3.15
One-hot CutMix	15.89	3.32
Scheduled CutMix	14.72	3.17
Complete-label CutMix	15.17	3.10

Table 8: Performance of CutMix variants on CIFAR-100.

CIFAR-10, CutMix also enhances the classification performances by +0.97%, outperforming Mixup and Cutout performances.

CutMix

- Summary

- What is CutMix?

- : Cutout, Mixup에서 쓰인 방법론을 응용하여 모델의 Generalization 과 Localization 성능을 향상하는 Augmentation Method.

- > **Uniform Distribution**에서 Combination ratio λ 를 정하고 이에 따라 지정된 직사각형의 Crop 영역을 다른 이미지와 섞어 새로운 이미지를 만들어 낸다.

- Limitation

- : 랜덤성에 의존, 매번 실행 결과가 다를 수 있음